Formation Data Scientist Machine Learning

Projet 3 :

Anticipez les besoins en consommations de bâtiments

Faïza KHELLADI

Context

Ville de Seattle

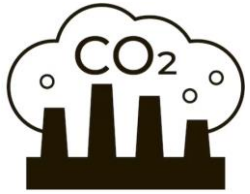


Neutre en émissions de carbone











Relevés de consommation de la ville

Analyse de données "Building Energy Benchmarking"

Prédiction des données :
- Consommation d'énergie
- Émission de CO2

Réduction du coût des relevés de la ville

Sommaire

- Processus de prédiction des données de bâtiments
- Données de la ville de Seattle
- Analyse descriptive liée aux données de bâtiments non-résidentiels
- Préparation des données
  - Feature Engineering
  - Encodage des données catégorielles
- Modélisation pour la prédiction de la conso. énergétique et et de l’émission CO2
  - Comparaison de différents modèles supervisés
  - Définition des variables influentes sur le modèle de prédiction
- Conclusion et perspectives

Processus de prédiction des données de bâtiments : Consommation énergétique et émission CO2

Identification des données pertinentes

- Analyse des données des bâtiments non-résidentiel
- Sélection des variables prédictives
- Sélection des variables cibles (consommation énergétique et émission de CO2)

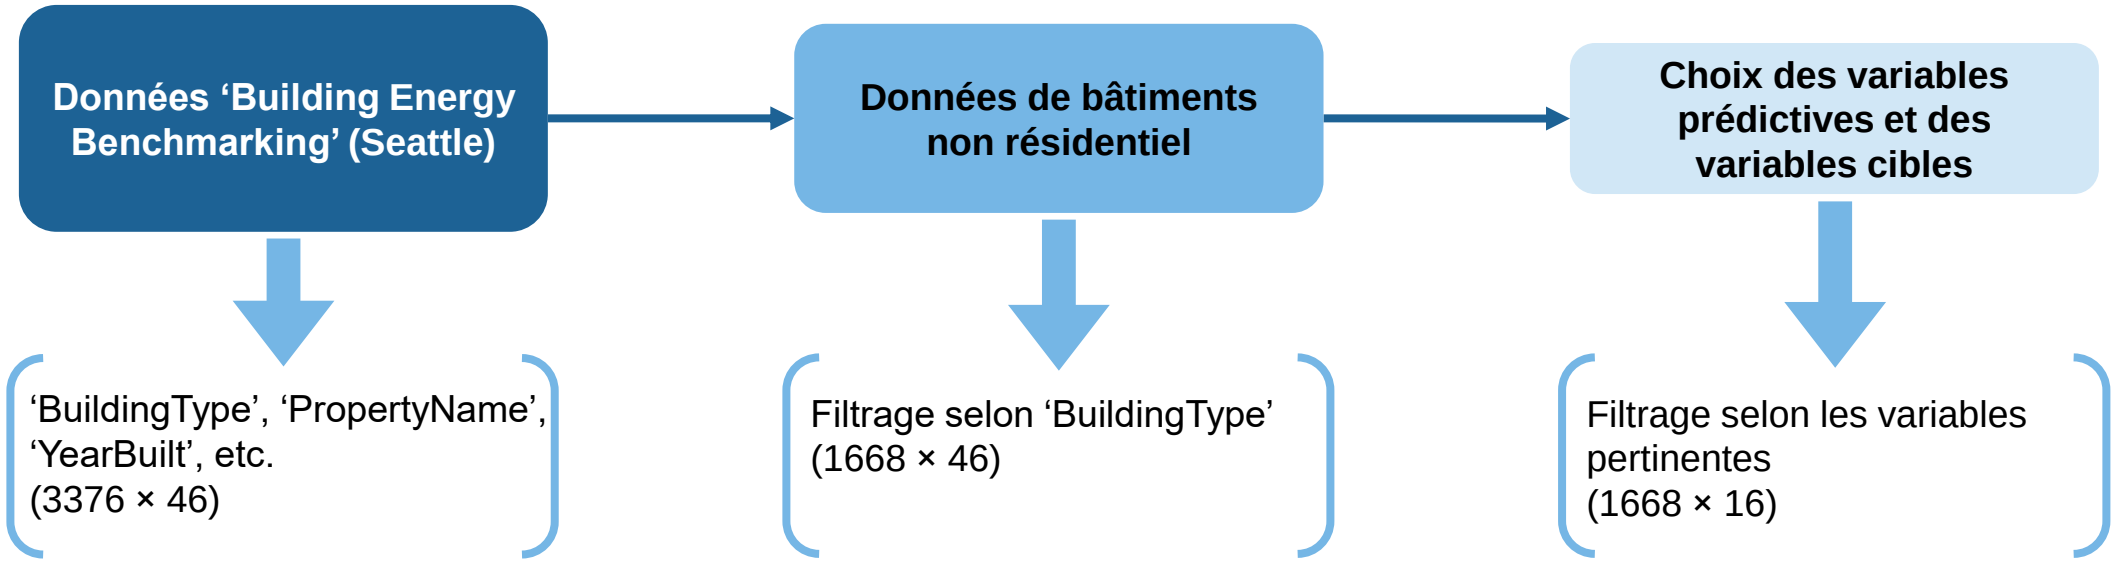
Préparation des données

- Feature engineering
- Séparation de données en X et y
- Encodage des données catégorielles

Prédiction des données cibles et réduction de coût de recensement

- Comparaison de différents modèles supervisés
- Choix du modèle supervisé
- Définition des variables influentes

Données de la ville de Seattle



BuildingType

- Multifamily LR (1-4)
- Multifamily MR (5-9)
- Multifamily HR (10+)
- NonResidential
- SPS-District K-12
- Nonresidential COS
- Campus
- Nonresidential WA

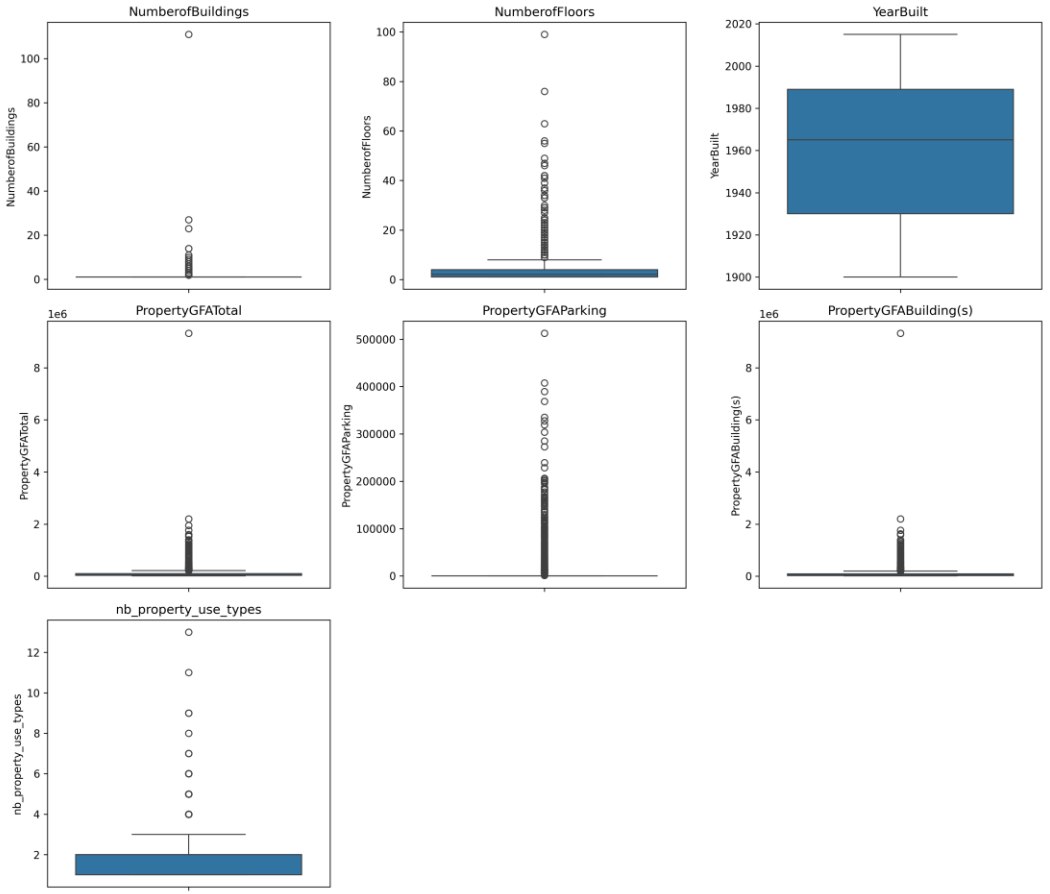
Variables prédictives

- PrimaryPropertyType
- Neighborhood
- NumberofBuildings
- NumberofFloors
- YearBuilt
- PropertyGFATotal
- LargestPropertyUseType
- LargestPropertyUseTypeGFA
- SecondLargestPropertyUseType
- SecondLargestPropertyUseTypeGFA
- ThirdLargestPropertyUseType
- ThirdLargestPropertyUseTypeGFA
- Electricity(kBtu)
- NaturalGas(kBtu)

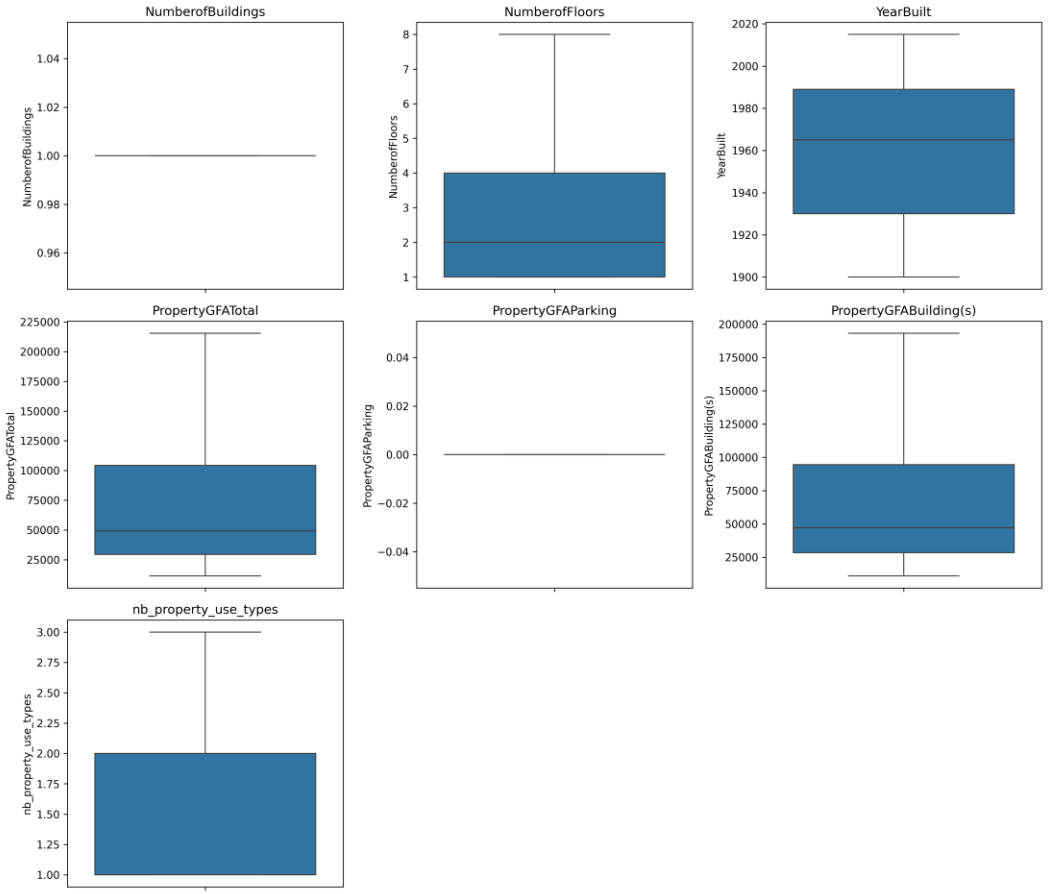
Variables cibles

- SiteEnergyUseWN(kBtu)
- TotalGHGEmissions

Analyse descriptive liée aux données de bâtiments non-résidentiels



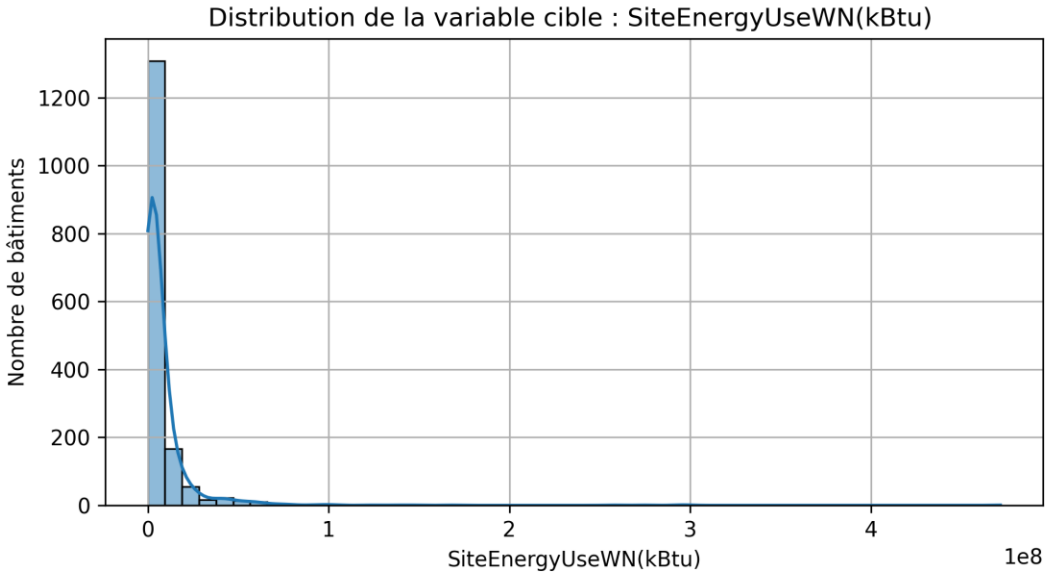
Zoom



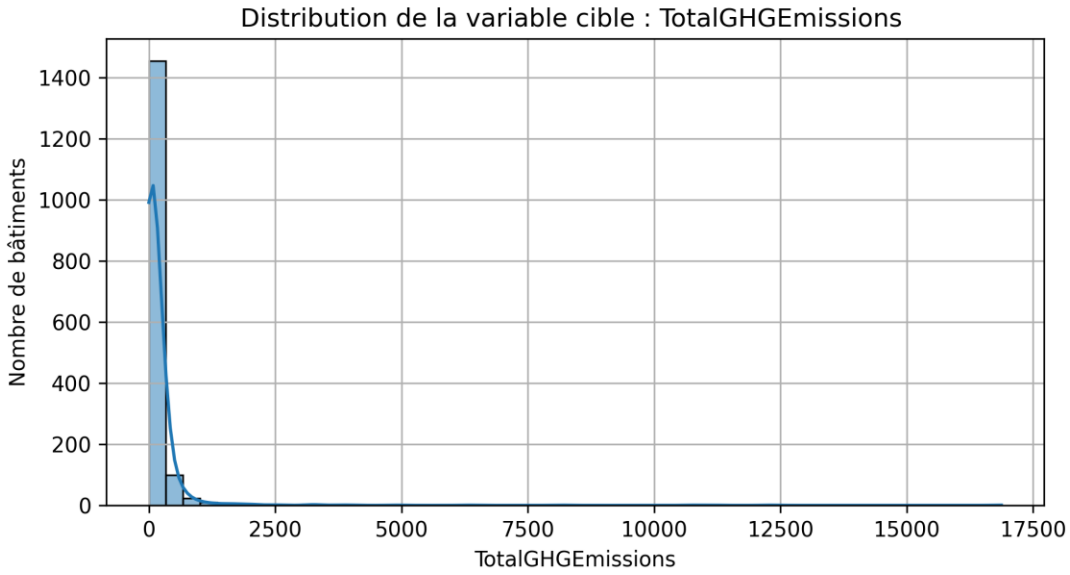
Bâtiments non-résidentiels présentant une forte diversité

Analyse descriptive liée au données de bâtiments non-résidentiels

Consommation énergétique



Émission CO2



Préparation des données

Feature engineering

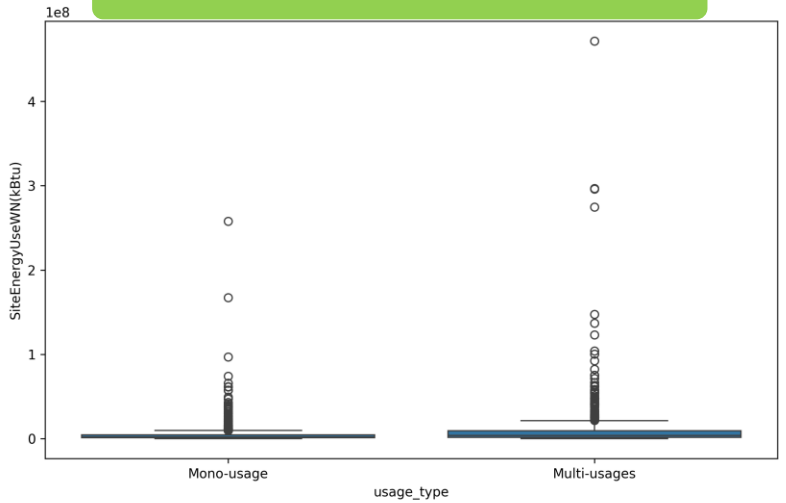
Création de la variable 1 :
Nombre de type d'usage du bâtiment

$$\text{nb_property_use_types} = \text{length(ListOfAllPropertyUseTypes)}$$

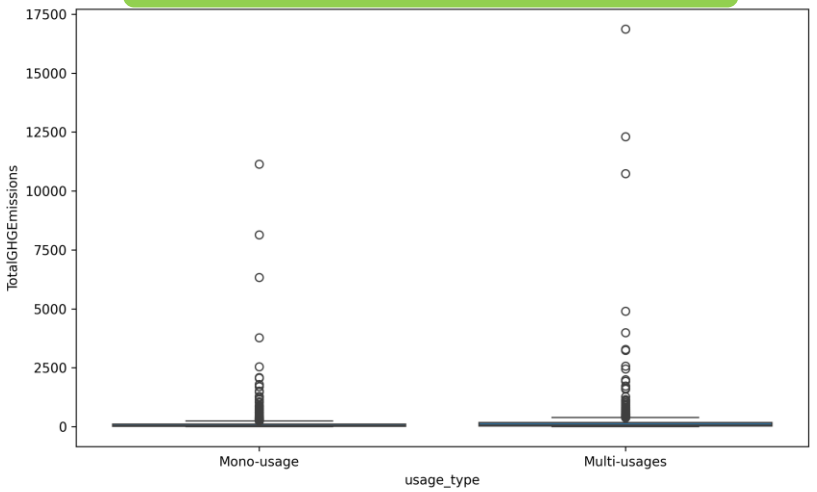
Création de la variable 2 :
Type d'usage : mono ou multi-usages

$$\text{usage_type} = \begin{cases} 0 \; si \; \text{nb_property_use_types} = 1 \; (\textbf{mono_usage}) \\ 1 \; si \; \text{nb_property_use_types} > 1 \; (\textbf{multi_usages}) \end{cases}$$

Consommation énergétique



Émission CO2



Préparation des données

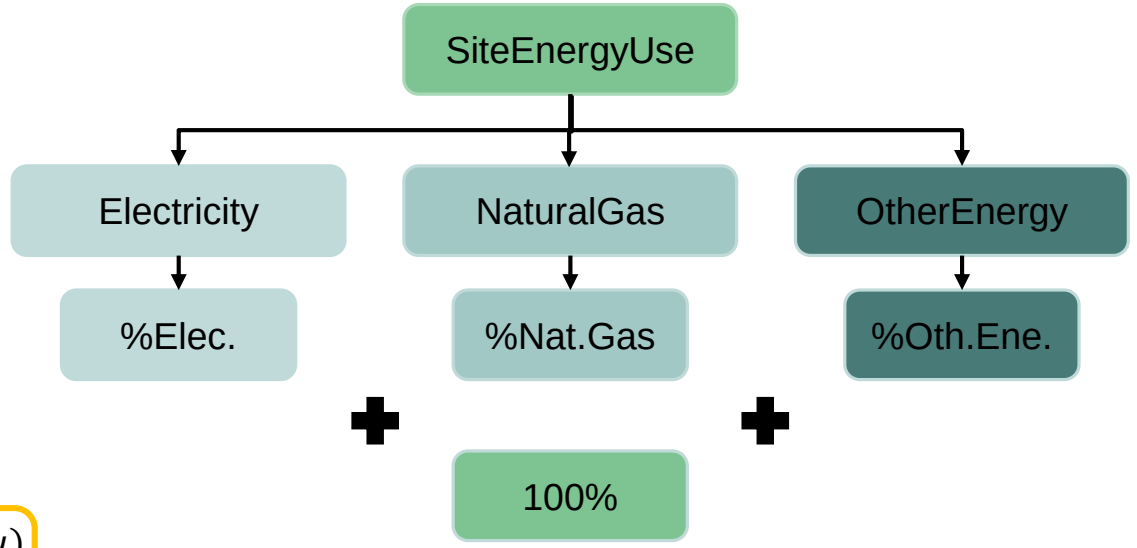
Feature engineering

Création de la variable 3 :
Pourcentage du type de consommation : électricité, gaz ou autre

$$\text{Electricity\%} = \frac{Electricity(kBtu)}{SiteEnergyUse(kBtu)} \times 100$$

$$\text{NaturalGas\%} = \frac{\text{NaturalGas}(kBtu)}{SiteEnergyUse(kBtu)} \times 100$$

$$\text{OtherEnergy\%} = \frac{\text{OtherEnergy}(kBtu)}{SiteEnergyUse(kBtu)} \times 100$$



⚠ Si $Electricity(kBtu) + \text{NaturalGas}(kBtu) > SiteEnergyUse(kBtu)$
→ normaliser selon la somme

Création de la variable 4 :
Âge du bâtiment

$$\text{BuildingAge} = 2016 - YearBuilt$$

Préparation des données

Feature engineering

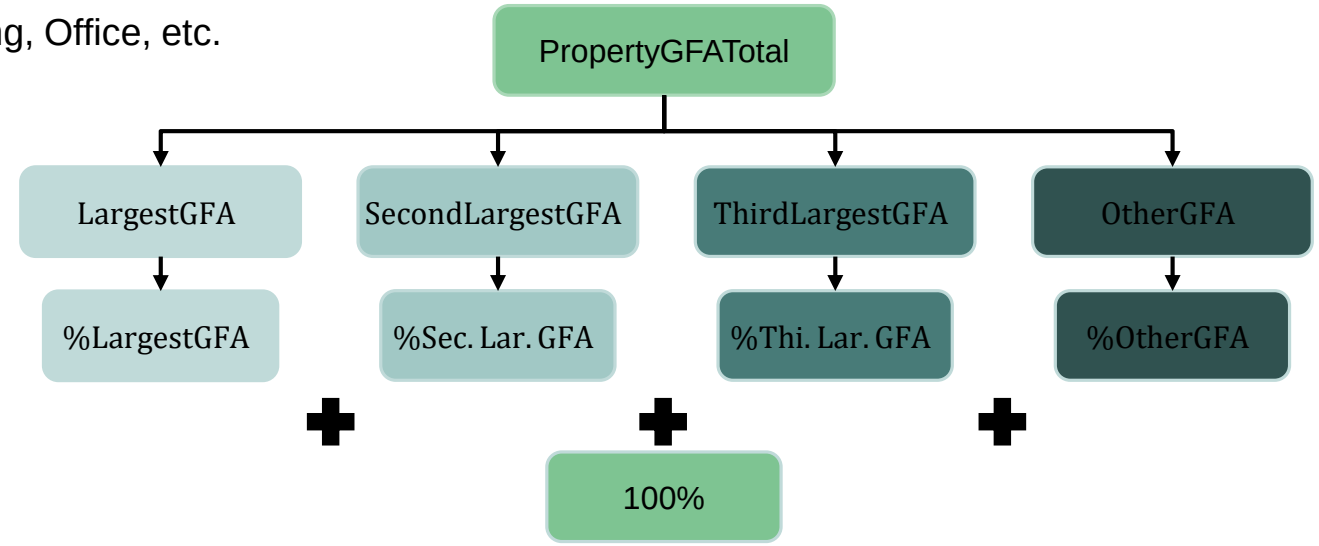
Création de la variable 5 (1/2) :
Pourcentage de surface selon le type de bâtiment : Hotel, Parking, Office, etc.

$$\text{LargestGFA\%} = \frac{LargestPropertyUseTypeGFA}{PropertyGFATotal} \times 100$$

$$\text{SecondLargestGFA\%} = \frac{SecondLargestPropertyUseTypeGFA}{PropertyGFATotal} \times 100$$

$$\text{ThirdLargestGFA\%} = \frac{ThirdLargestPropertyUseTypeGFA}{PropertyGFATotal} \times 100$$

$$\text{OtherGFA\%} = \frac{OtherGFA}{PropertyGFATotal} \times 100$$



⚠ Si $LargestPropertyUseTypeGFA + SecondLargestPropertyUseTypeGFA + ThirdLargestPropertyUseTypeGFA > PropertyGFATotal$ → normaliser à la somme

Préparation des données

Feature engineering

Création de la variable 5 (2/2) :
Pourcentage de surface selon le type de bâtiment : Hotel, Parking, Office, etc.

Création d'un dataframe avec :
- catégories de $Largest(SecondLargest,$

Utilisation de pivot_table
- Chaque ligne représente un bâtiment avec un ID et des % des surfaces des catégories
- Dataframe joint au dataset étudié

building_id	Property_use_type	GFA%
0	Hotel	100
1	Hotel	80
1	Parking	15
1	Restaurant	5
⋮	⋮	⋮

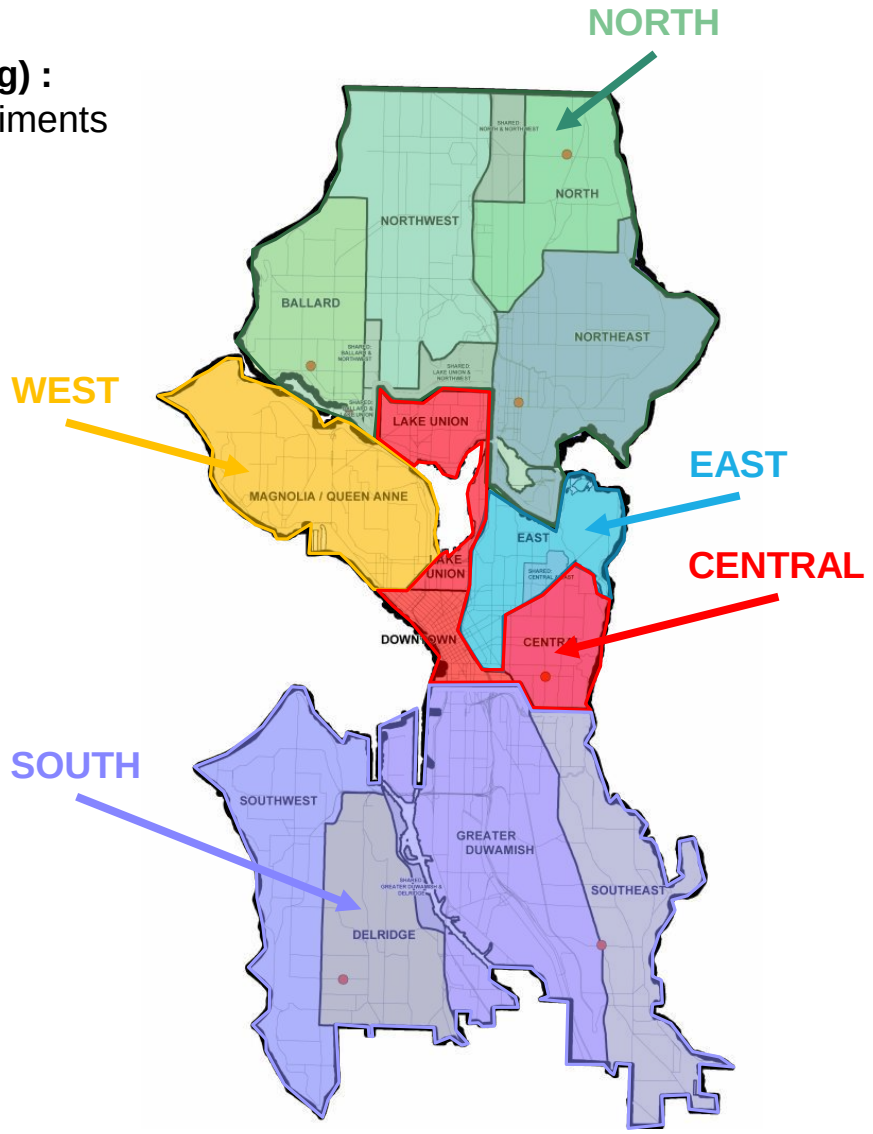
building_id	PropertyUseType_Hotel	PropertyUseType_Parking	PropertyUseType_Restaurant	…
0	100	0	0	…
1	80	15	5	…
⋮	⋮	⋮	⋮	⋱

Préparation des données

Feature engineering

Création de la variable 6 (mapping) :
Regroupement des quartiers de bâtiments

Neighborhood (14)
- GREATER DUWAMISH
- DOWNTOWN
- MAGNOLIA / QUEEN ANNE
- LAKE UNION
- NORTHEAST
- EAST
- NORTHWEST
- BALLARD
- NORTH
- CENTRAL
- DELRIDGE
- SOUTHEAST
- SOUTHWEST
- DELRIDGE NEIGHBORHOODS



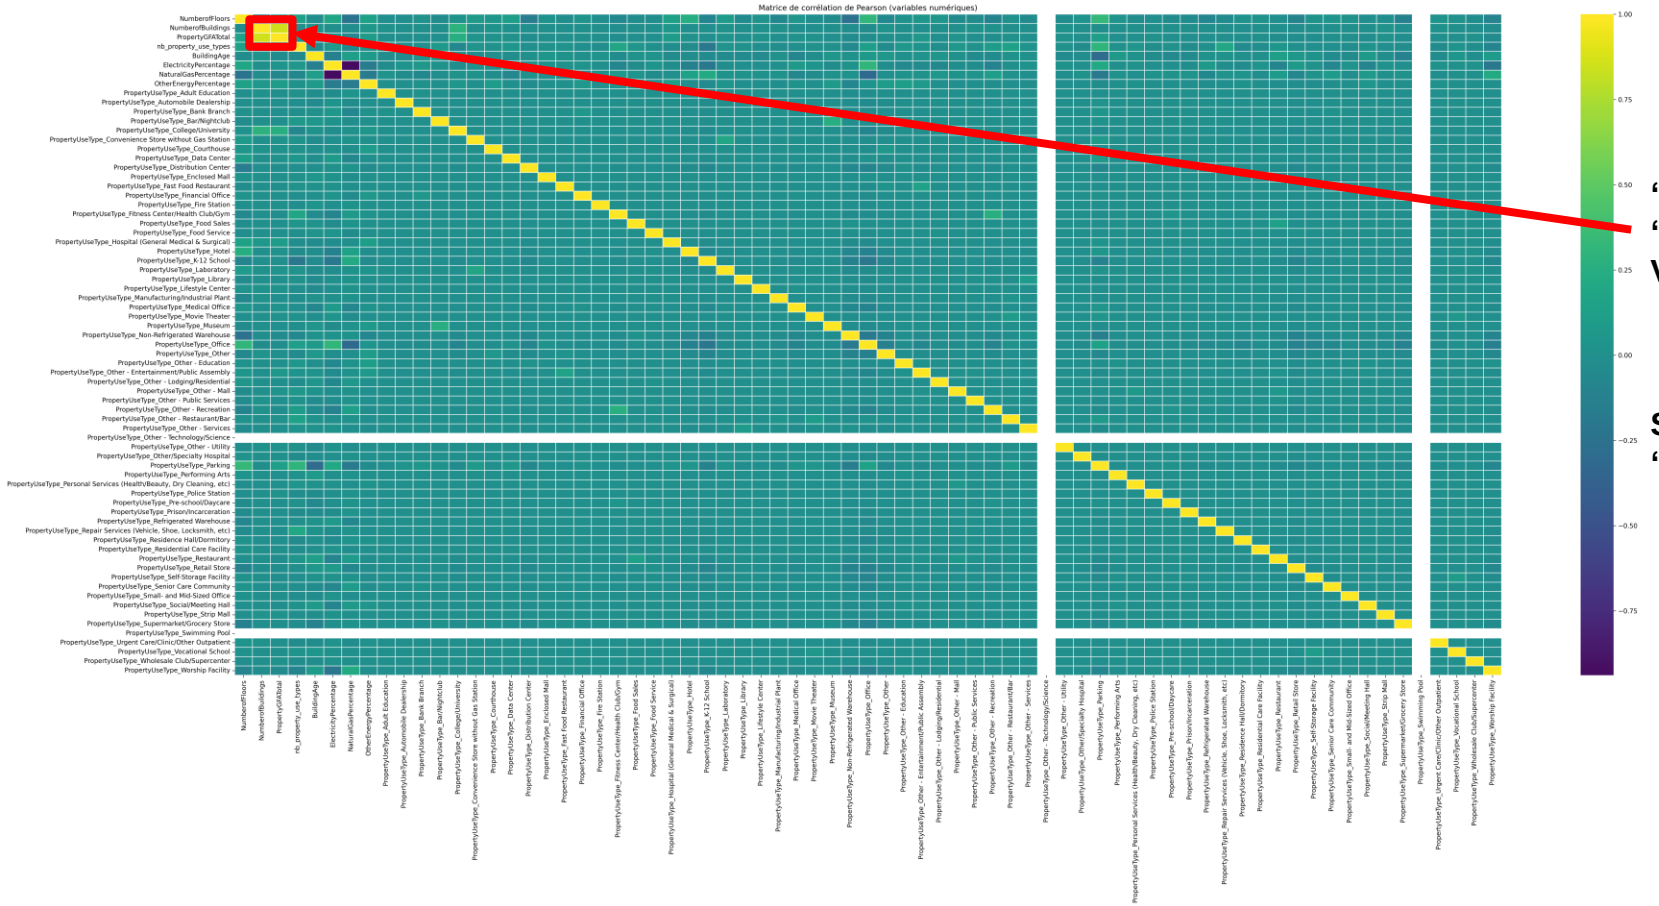
Neighborhood _grouped (5)
- **NORTH:**
  - BALLARD
  - NORTH
  - NORTHEAST
  - NORTHWEST
- **SOUTH**:
  - GREATER DUWAMISH
  - DELRIDGE
  - DELRIDGE NEIGHBORHOODS
  - SOUTHEAST
  - SOUTHWEST
- **EAST:**
  - EAST
- **WEST:**
  - MAGNOLIA / QUEEN ANNE
  - MAGNOLIA / QUEENANNE
- **CENTRAL:**
  - CENTRAL
  - DOWNTOWN
  - LAKE UNION

Préparation des données

Feature engineering

Suppression de variables corrélées
Variables corrélées à plus de 70%

Variables numériques
- NumberofFloors
- NumberofBuildings
- PropertyGFATotal
- nb_property_use_types
- BuildingAge
- ElectricityPercentage
- NaturalGasPercentage
- OtherEnergyPercentage
- PropertyUseType_(all cat.)



‘NumberofBuildings’ & ‘PropertyGFATotal’ : Variables très corrélées

Suppression de ‘NumberofBuildings’

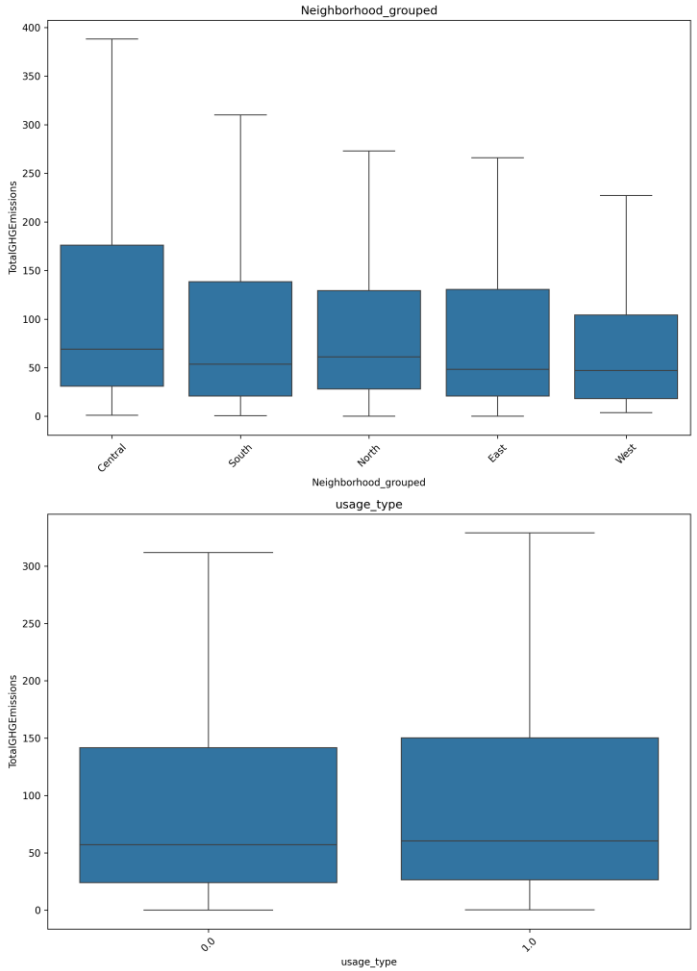
Préparation des données

Feature engineering

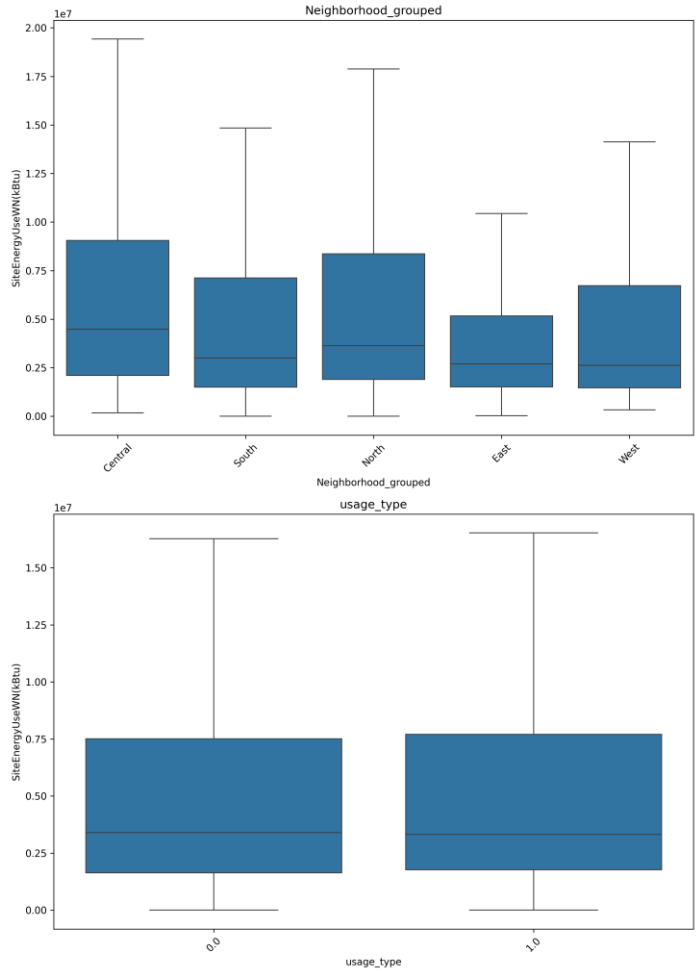
Variables catégorielles

- Neighborhood_grouped
- usage_type

Analyse descriptive de la consommation d'énergie

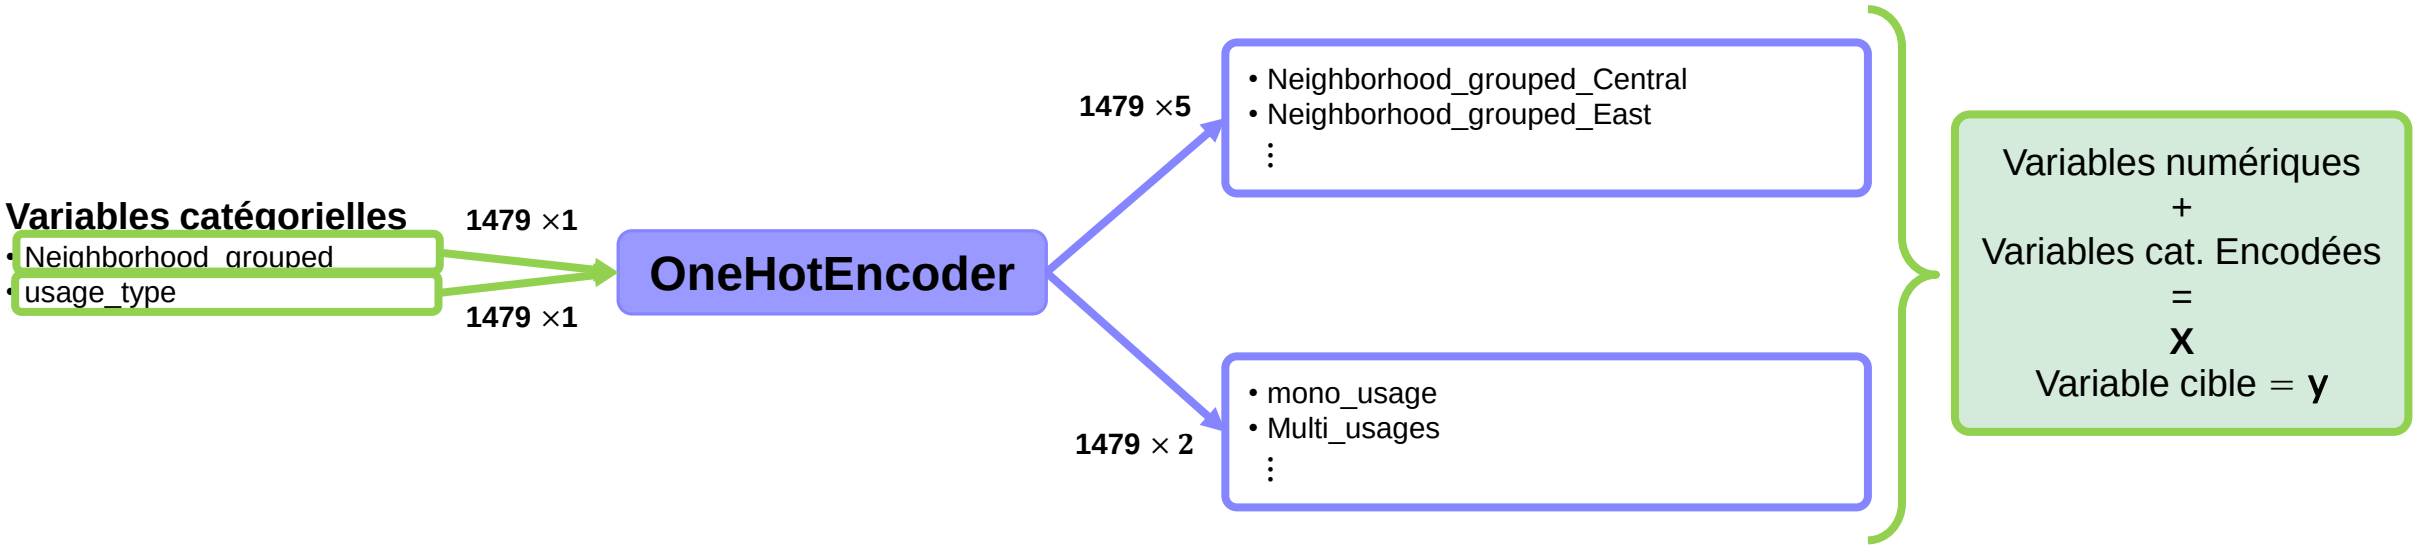


Analyse descriptive de l'émission CO2



Préparation des données

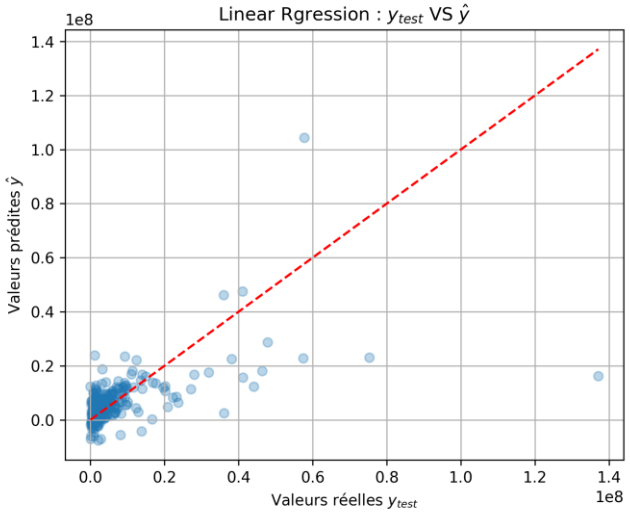
Encodage des données



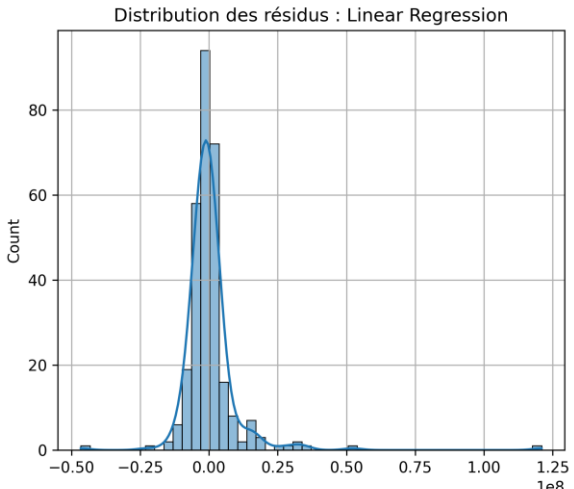
Modélisation pour la prédiction

Comparaison de différents modèles supervisés (1/5) : Linear Regression

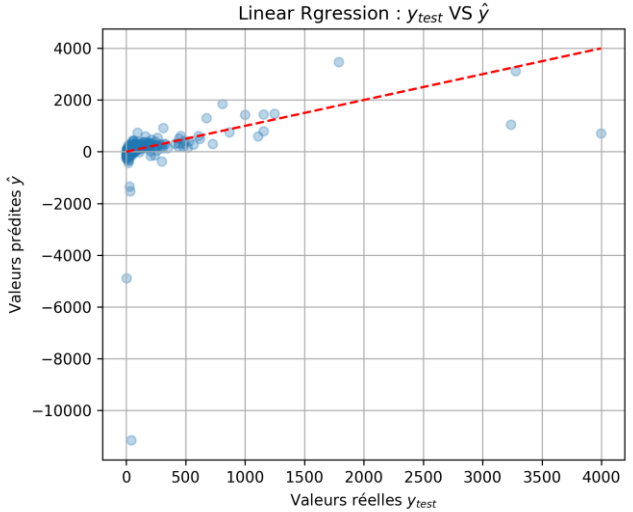
Prédiction de la consommation d'énergie



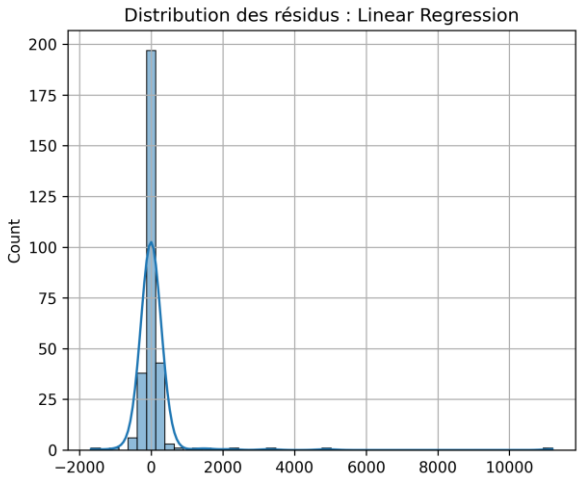
R2_train: 0.341
R2_test: -13.031
RMSE: 40295825.087
MAE: 6754478.391



Prédiction de l'émission CO2



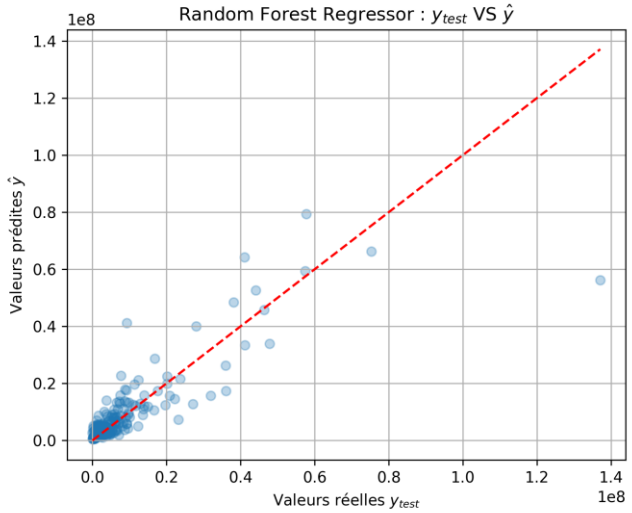
R2_train: 0.490
R2_test: -2.741
RMSE: 781.153
MAE: 203.514



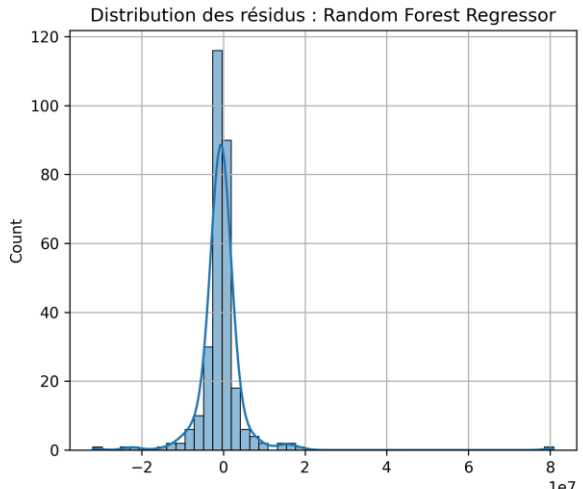
Modélisation pour la prédiction

Comparaison de différents modèles supervisés (2/5): Random Forest Reg.

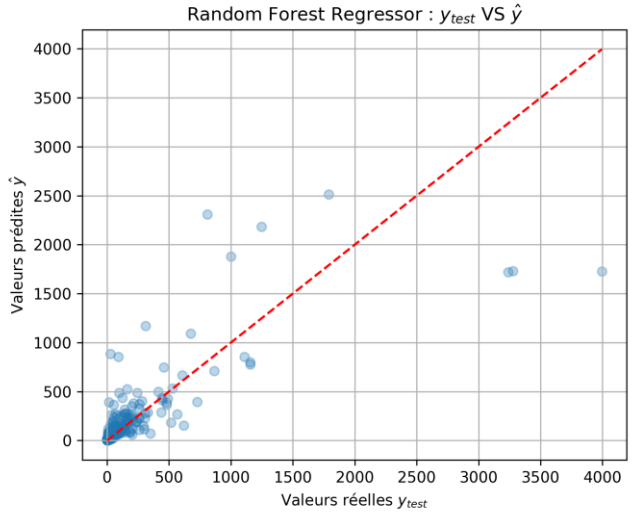
Prédiction de la consommation d'énergie



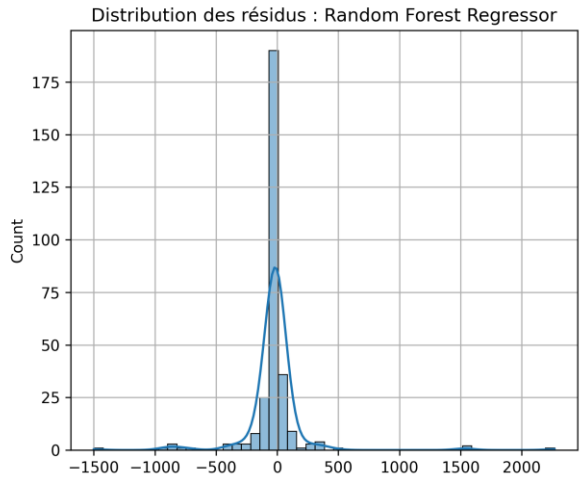
R2_train: 0.910
R2_test: 0.723
RMSE: 6533893.019
MAE: 2748427.701



Prédiction de l'émission CO2



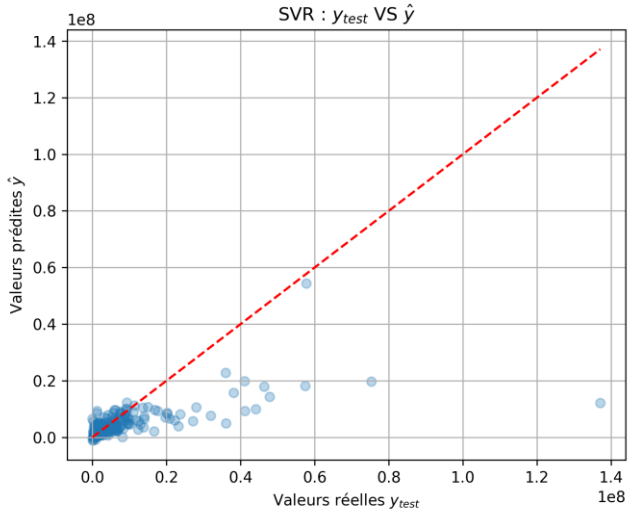
R2_train: 0.862
R2_test: 0.605
RMSE: 253.906
MAE: 91.693



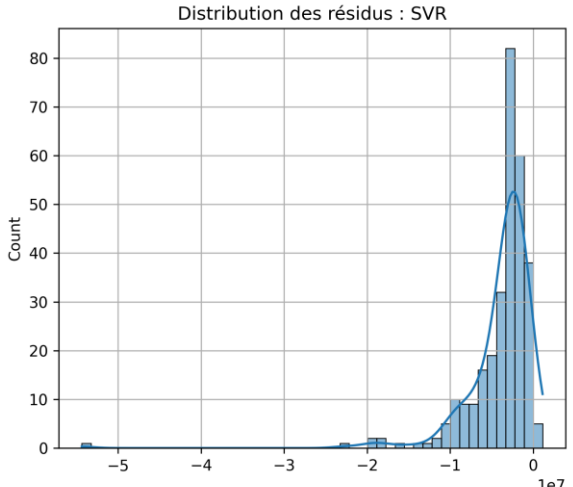
Modélisation pour la prédiction

Comparaison de différents modèles supervisés (3/5) : SVR

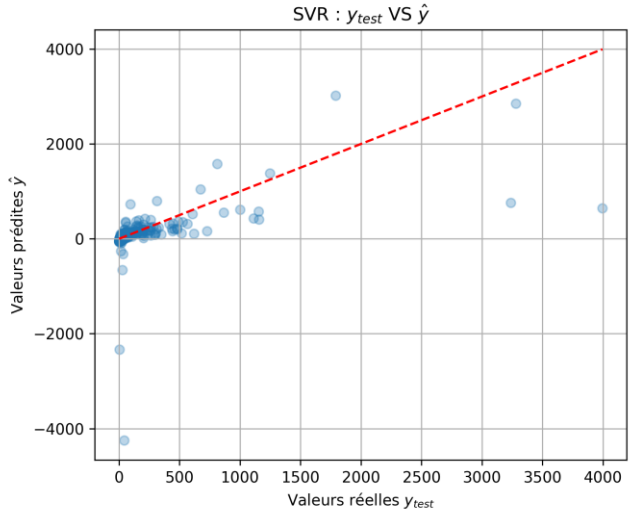
Prédiction de la consommation d'énergie



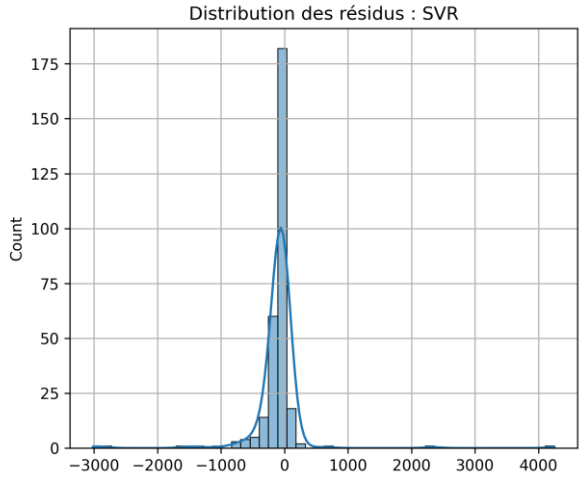
R2_train: 0.226
R2_test: 0.317
RMSE: 10268340.327
MAE: 3646024.658



Prédiction de l'émission CO2



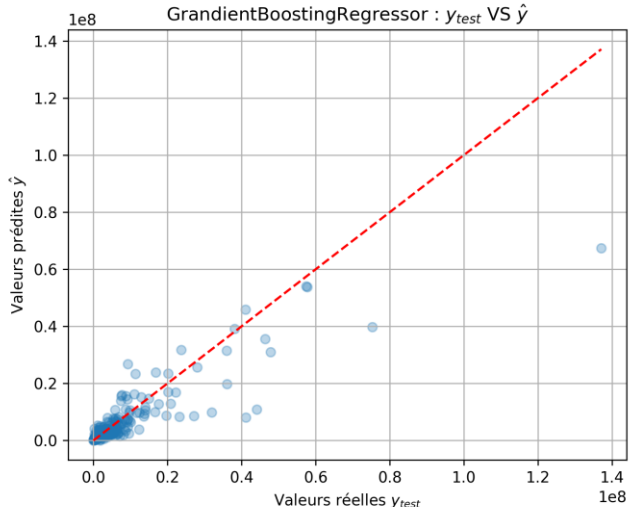
R2_train: 0.454
R2_test: -0.015
RMSE: 406.813
MAE: 120.294



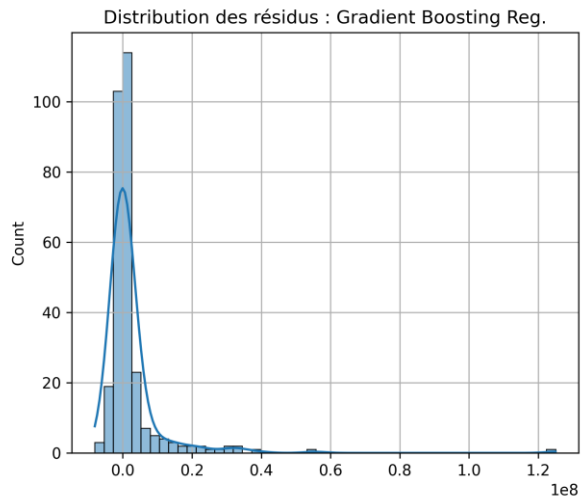
Modélisation pour la prédiction

Comparaison de différents modèles supervisés (4/5) : Gradient Boosting Reg.

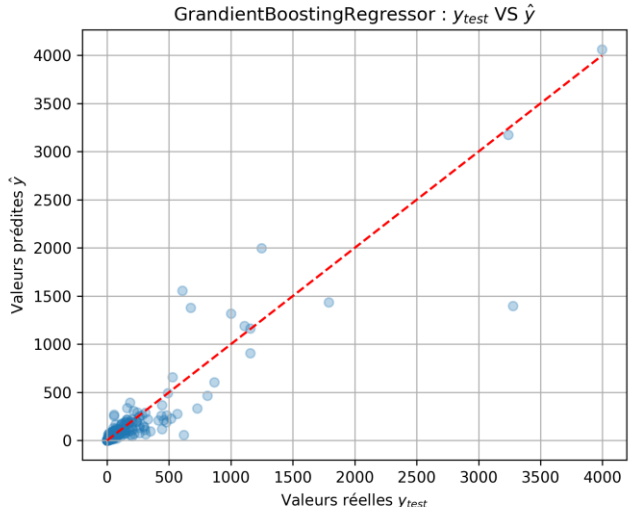
Prédiction de la consommation d'énergie



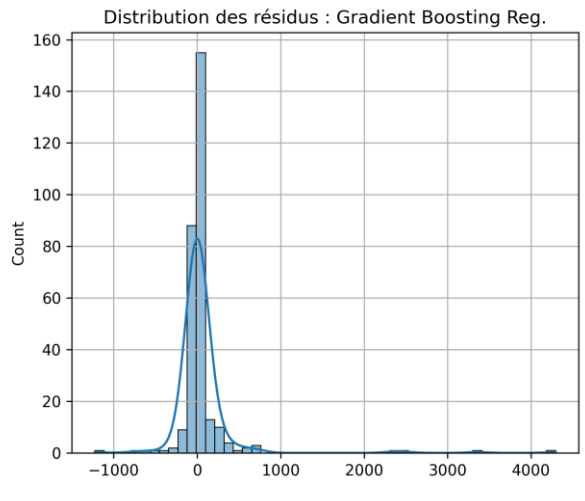
R2_train: 0.836
R2_test: 0.735
RMSE: 6392666.194
MAE: 2469284.300



Prédiction de l'émission CO2



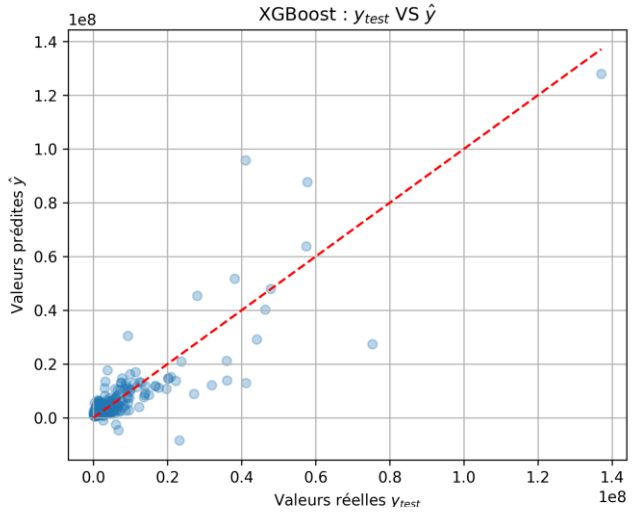
R2_train: 0.878
R2_test: 0.840
RMSE: 161.392
MAE: 55.859



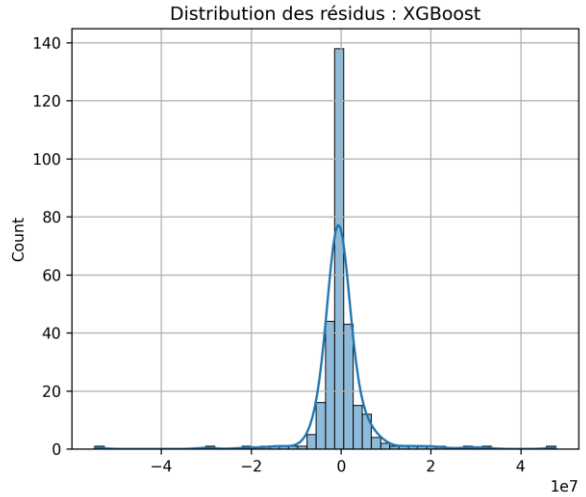
Modélisation pour la prédiction

Comparaison de différents modèles supervisés (5/5) : XGBoost

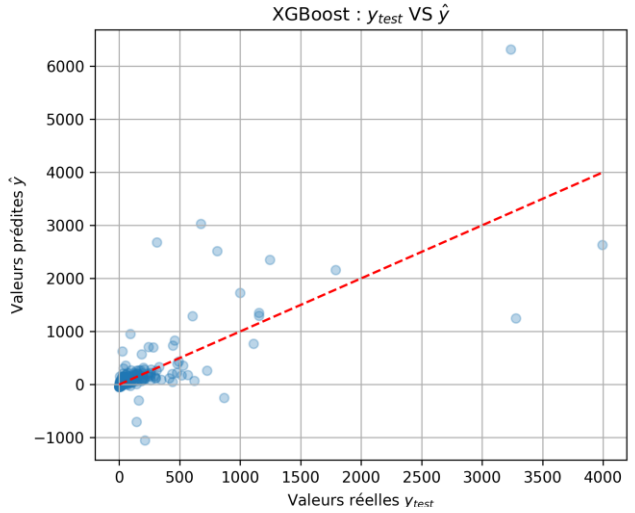
Prédiction de la consommation d'énergie



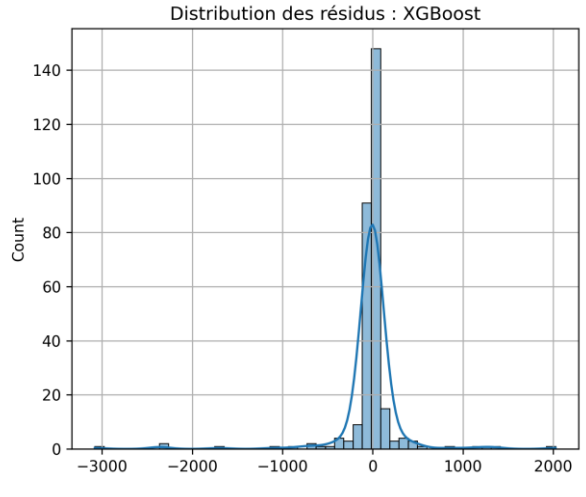
R2_train: 0.836
R2_test: 0.735
RMSE: 6392666.194
MAE: 2469284.300



Prédiction de l'émission CO2



R2_train: 0.878
R2_test: 0.840
RMSE: 161.392
MAE: 55.859



Modélisation pour la prédiction

Comparaison de différents modèles supervisés : Récapitulatif

Prédiction de la consommation d'énergie : SiteEnergyUseWN(kBtu)

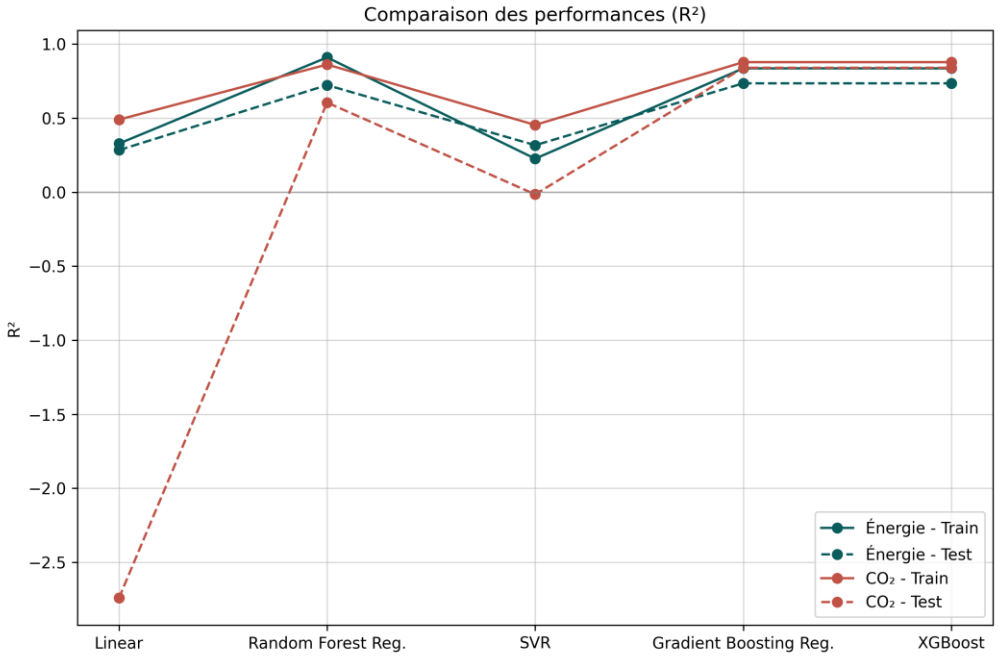
	Métriques				
Modèles de prédiction	R2 train	R2 test	RMSE	MAE	
Linear Regression	0.328	0.284	10510076.593	4982877.803	Sous-apprentissage
Random Forest Reg.	0.910	0.723	6533893.019	2748427.701	**Bon modèle**
SVR	0.226	0.317	10268340.327	3646024.658	Sous-apprentissage
Gradient Boosting Reg.	0.836	0.735	6392666.194	2469284.300	**Bon modèle**
XGBoost	0.836	0.735	6392666.194	2469284.300	**Bon modèle**

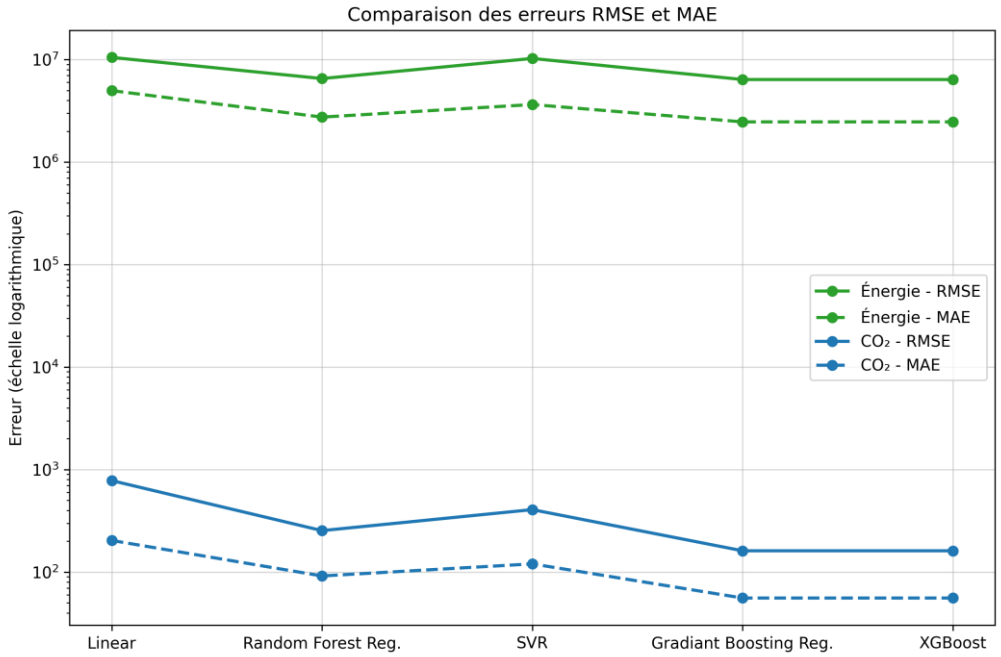
Prédiction de l'émission CO2 : TotalGHGEmissions

	Métriques				
Modèles de prédiction	R2 train	R2 test	RMSE	MAE	
Linear Regression	0.490	-2.741	781.153	203.514	Sous-apprentissage
Random Forest Reg.	0.862	0.605	253.906	91.693	**Bon modèle**
SVR	0.454	-0.015	406.813	120.294	Sous-apprentissage
Gradient Boosting Reg.	0.878	0.840	161.392	55.859	**Bon modèle**
XGBoost	0.878	0.840	161.392	55.859	**Bon modèle**

Modélisation pour la prédiction

Comparaison de différents modèles supervisés : Récapitulatif

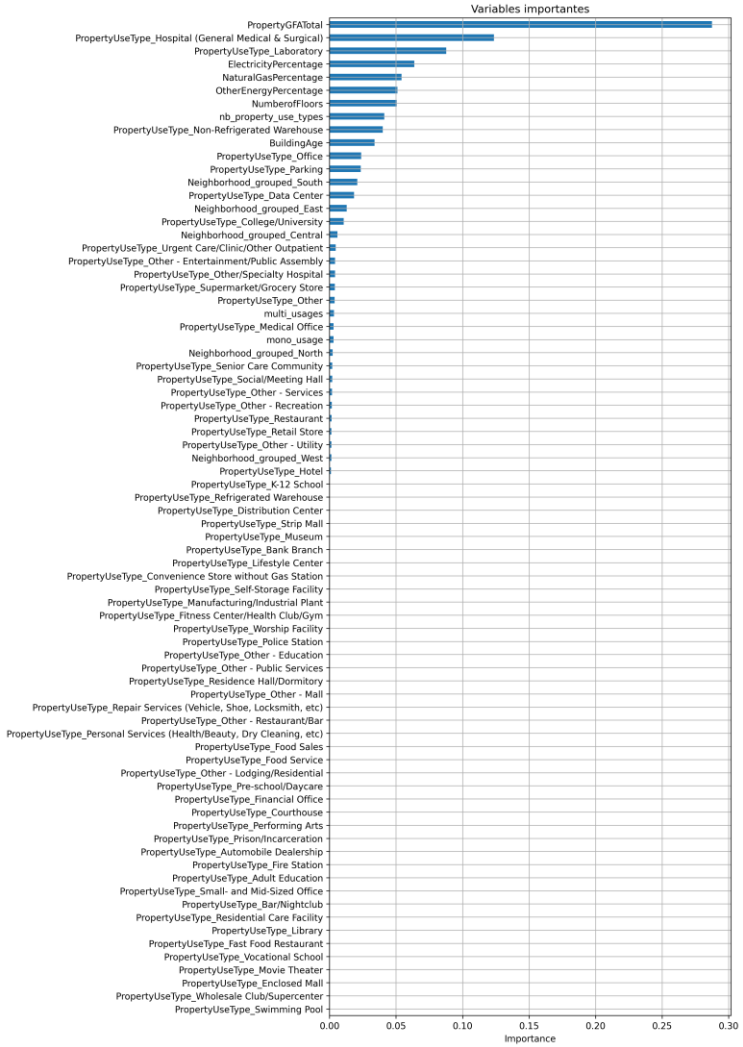




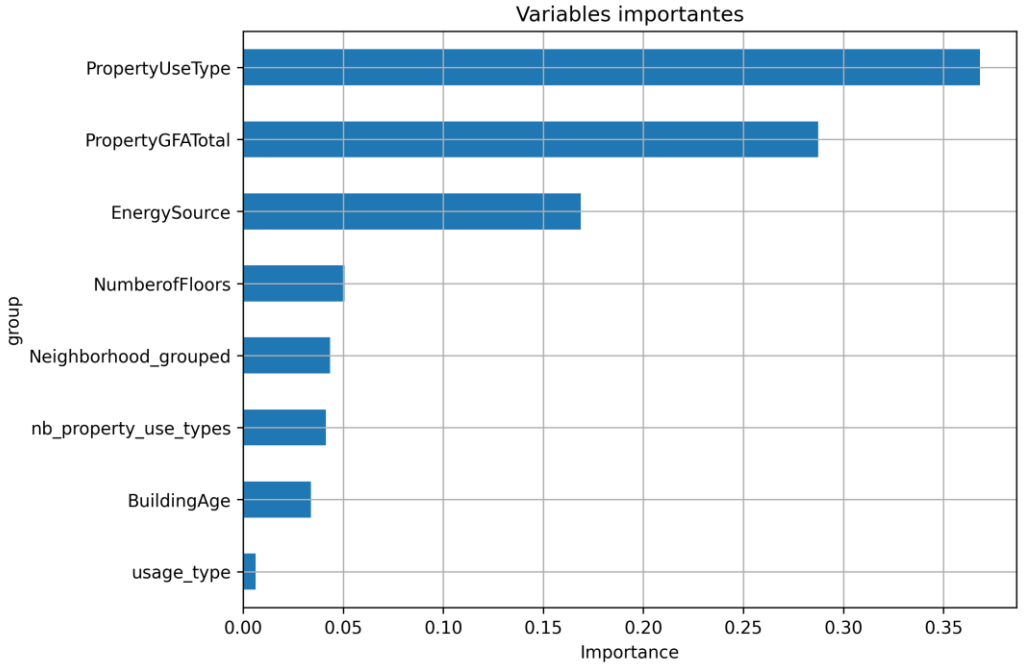
- Les modèles non linéaires capturent mieux la complexité des données
- Les hyperparamètres optimaux sont très proches entre le Gradient Boosting Reg. et le XGBoost → performances similaires

Modélisation pour la prédiction

Importance des variables sur le modèle : Prédiction de la consommation énergétique



Regroupement des variables catégorielles

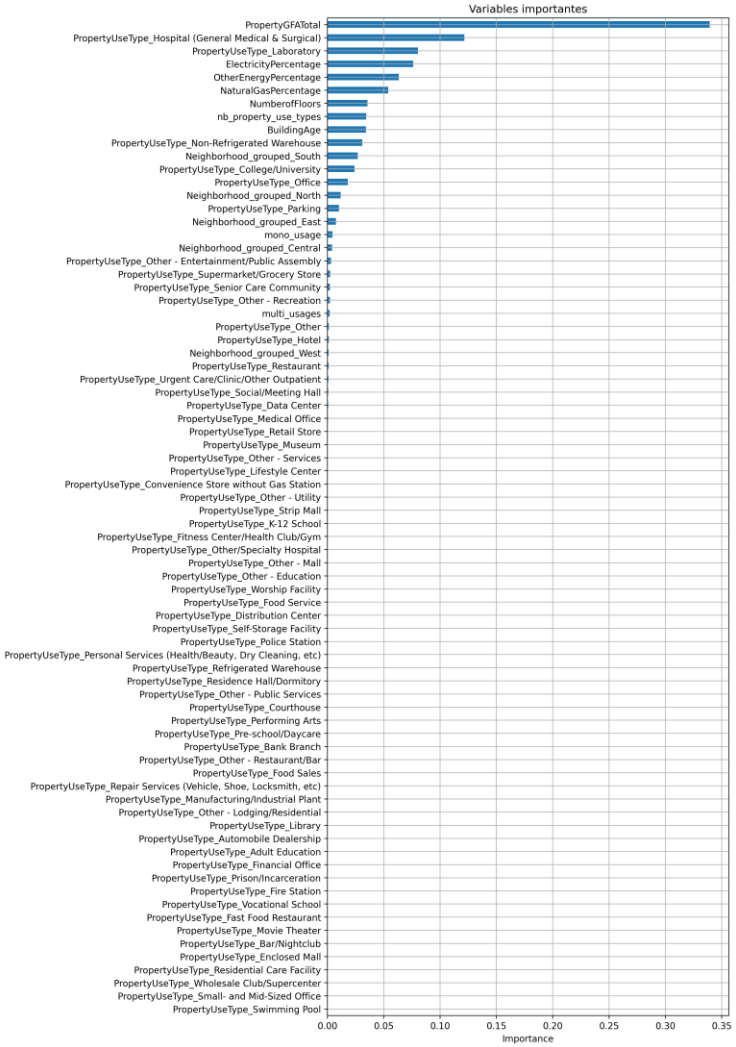


Variables dominantes :

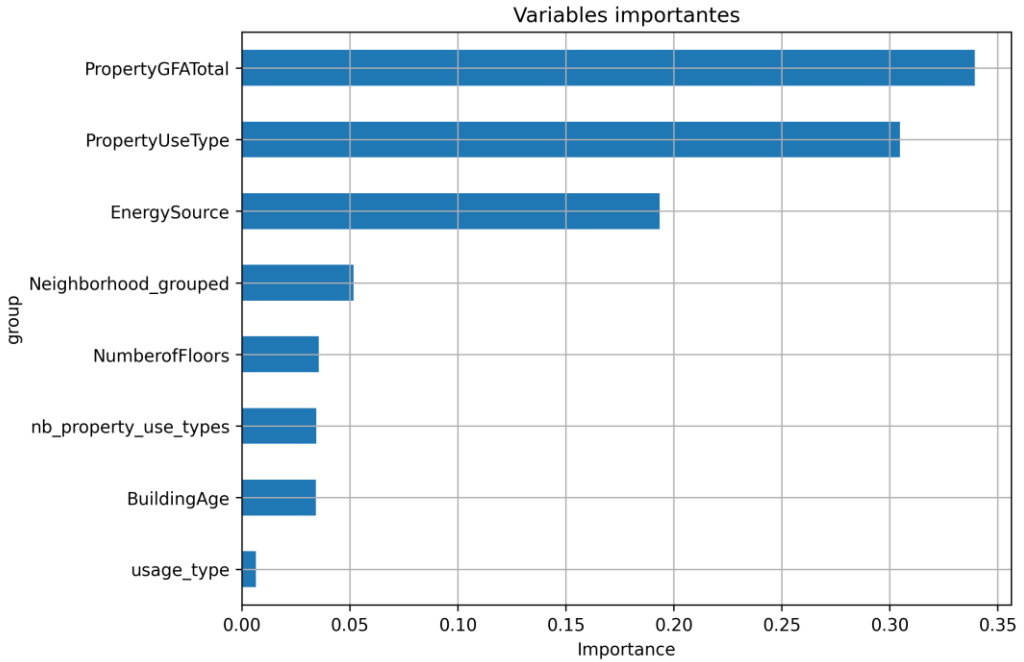
- PropertyUseType
- PropertyGFATotal
- EnergySource

Modélisation pour la prédiction

Importance des variables sur le modèle : Prédiction de l'émission CO2



Regroupement des variables catégorielles



Variables dominantes :

- PropertyGFATotal
- PropertyUseType
- EnergySource

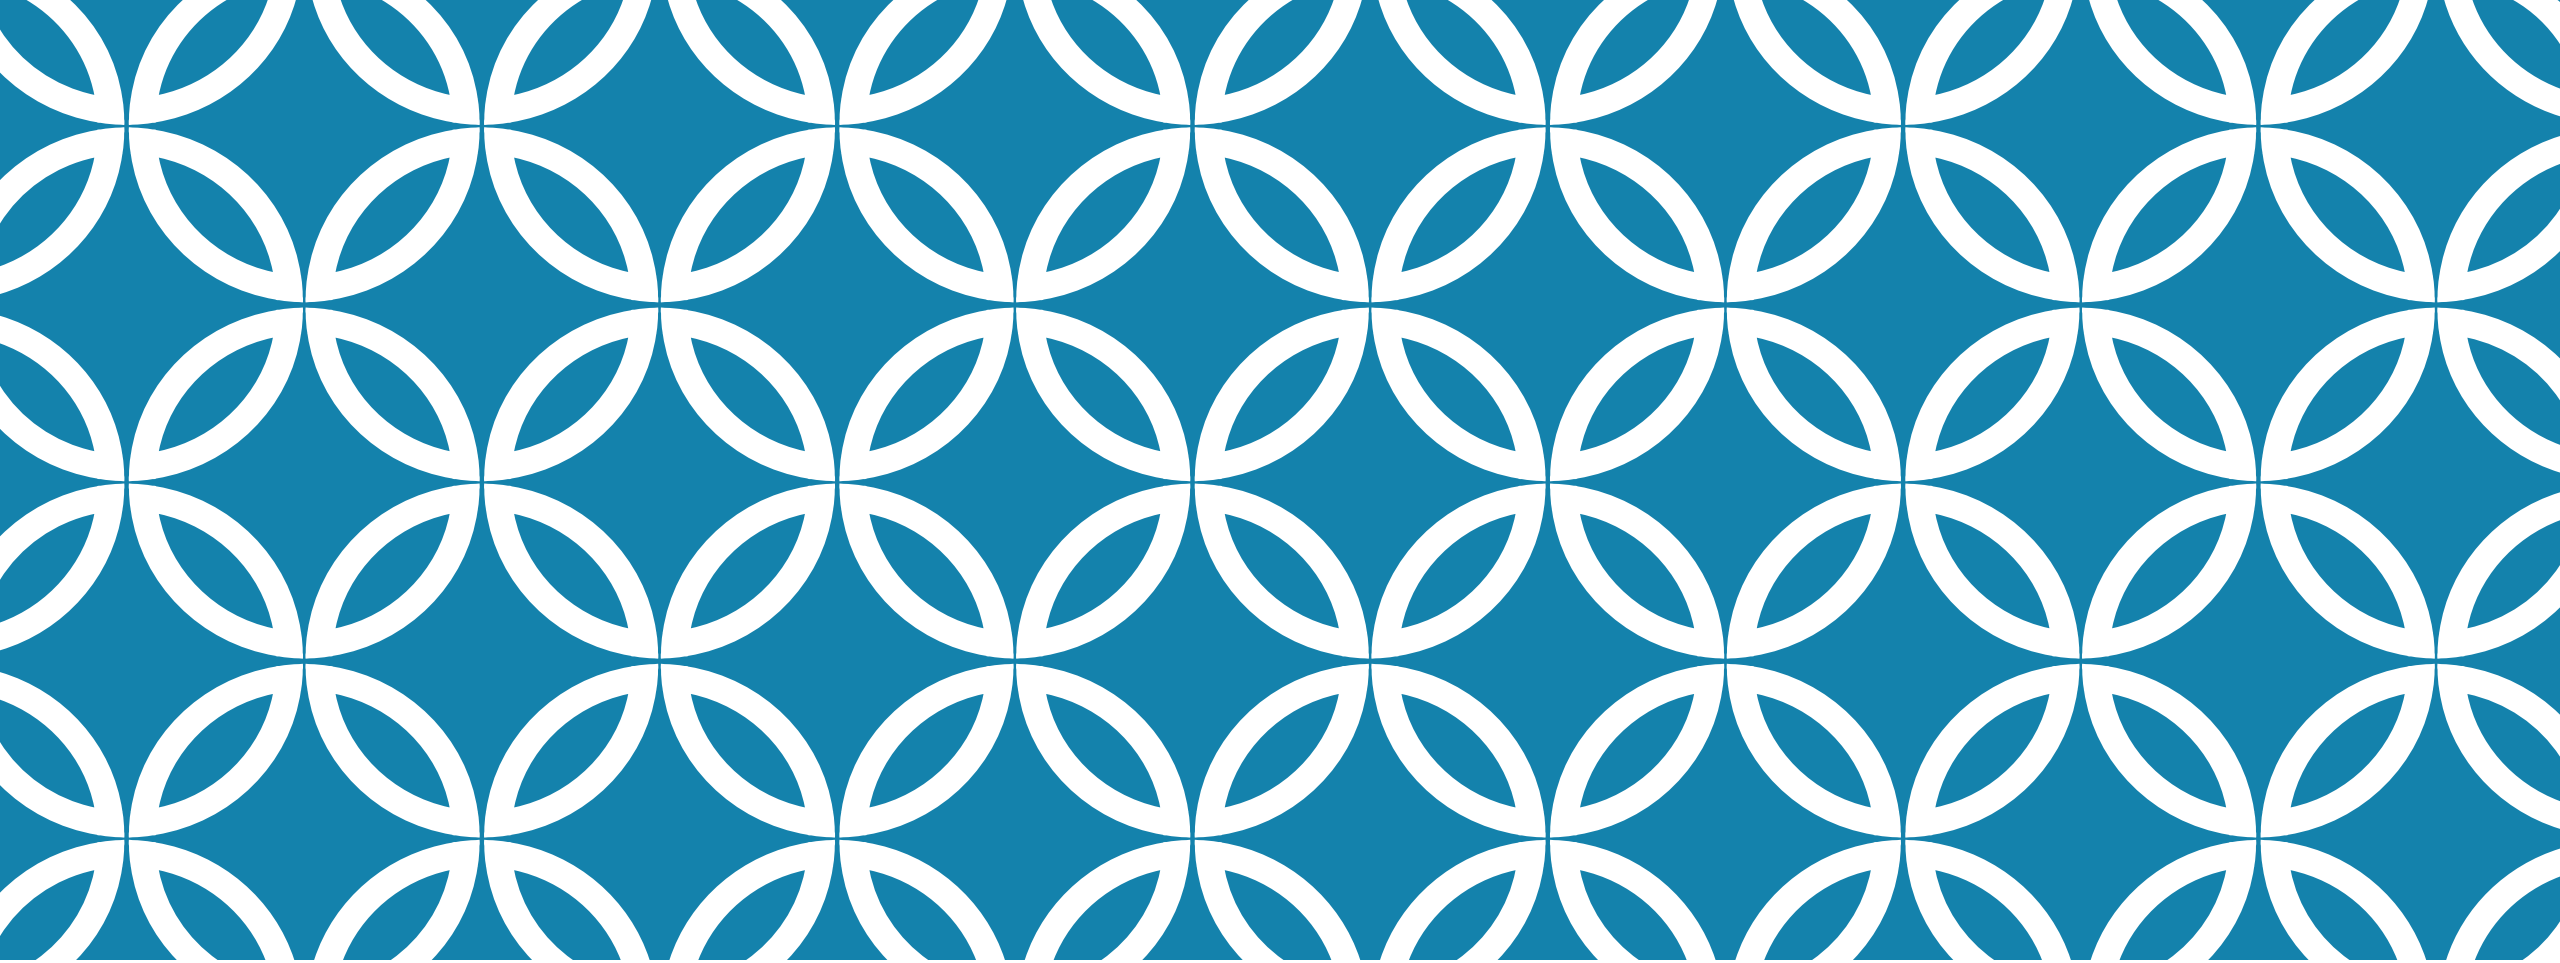
Conclusion et perspectives

Conclusion

- Les bâtiments non-résidentiels présentent une **forte hétérogénéité.**
- Les distributions de consommation énergétique et d'émissions de CO_2 sont fortement asymétriques
- Les modèles linéaires sont **sous-adaptés à la complexité**.
- Les modèles à base d'arbres (**Random Forest & Gradient Boosting Reg.**) offrent de **meilleures performances** pour la prédiction.
- Les variables les plus influentes sont principalement : la surface, le type d'usage et la source d'énergie.
- Le modèle permet de **réduire le coût des relevés** énergétiques en gardant une bonne précision prédictive

Perspectives

- Tester des modèles plus avancés (eg. XGBoost)
- Enrichir les données avec des informations climatiques ou d'usage réel.
- Étendre l'approche à d'autres villes ou à des bâtiments résidentiels.

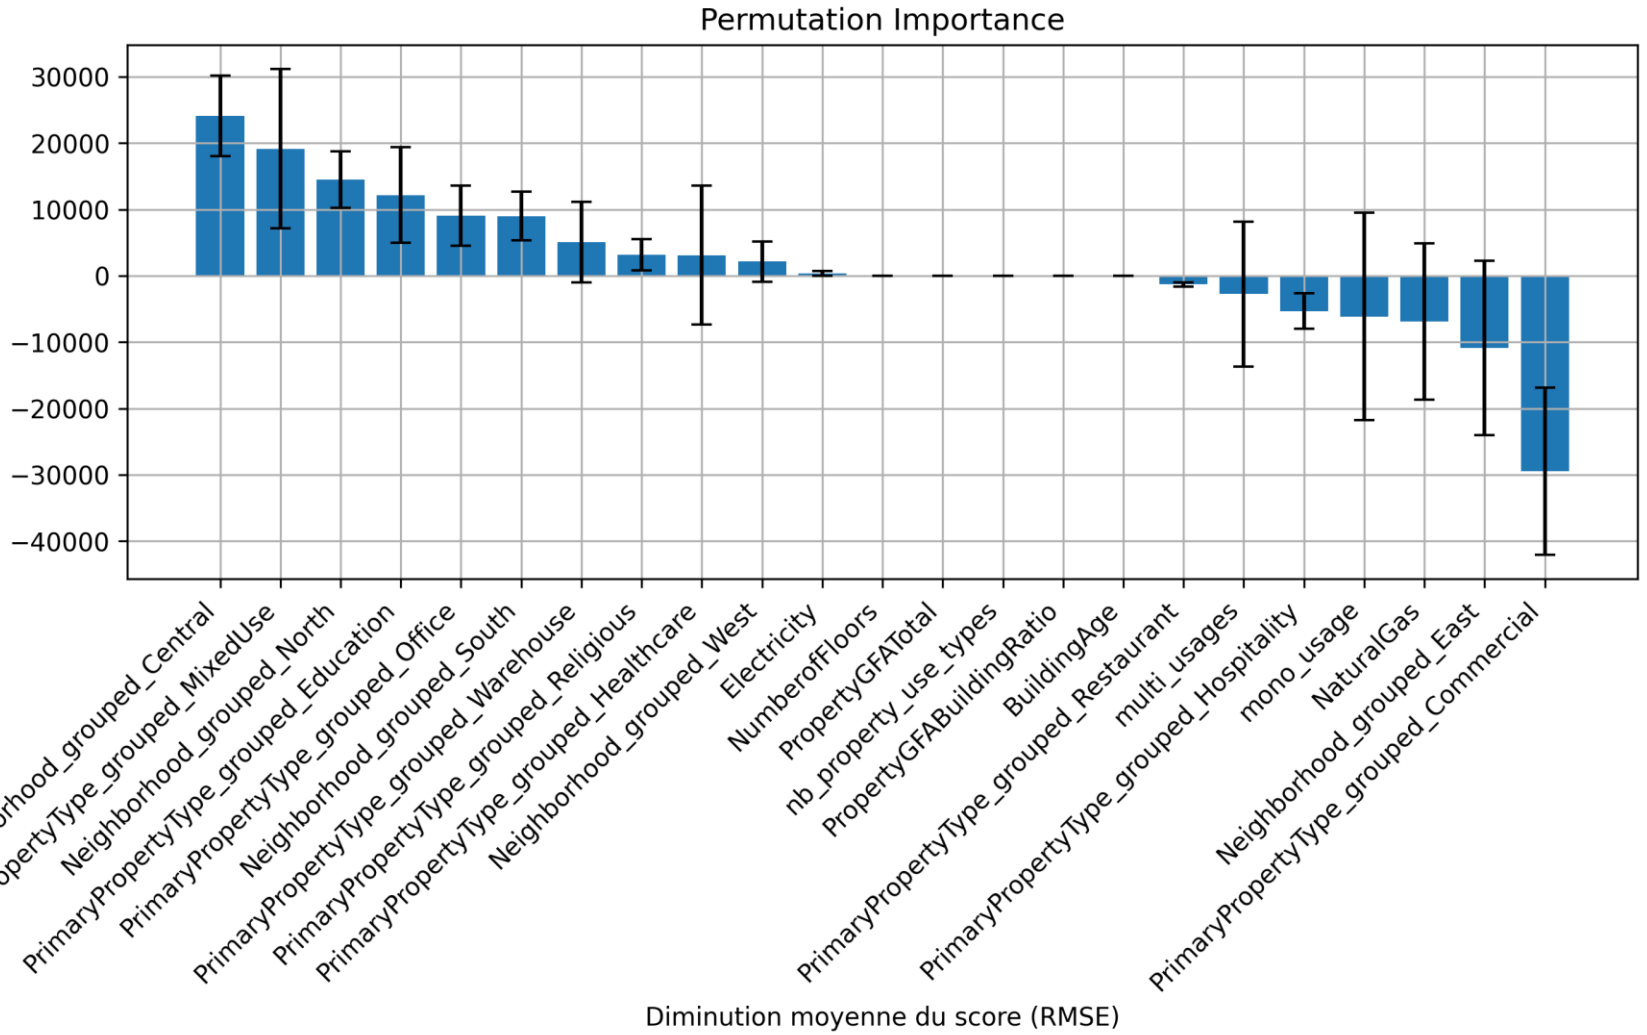


Merci pour votre attention

Faïza Khelladi

Modélisation pour la prédiction

Importance des variables : Prédiction de la consommation énergétique

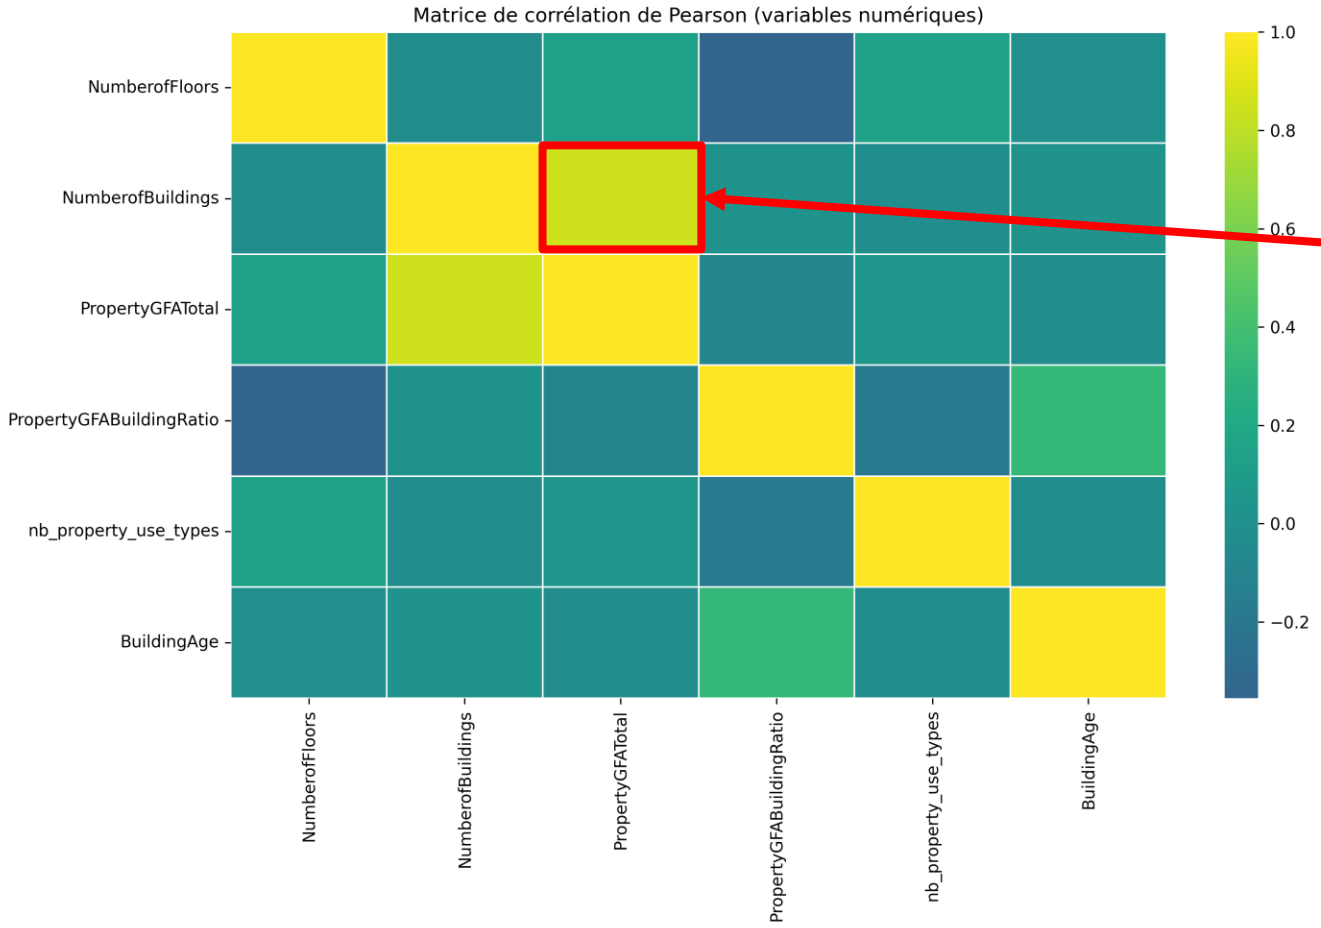


Préparation des données

Feature engineering

Suppression de variables corrélées
Variables corrélées à plus de 70%

Variables numériques
- NumberofFloors
- NumberofBuildings
- PropertyGFATotal
- PropertyGFABuildingRatio
- nb_property_use_types
- BuildingAge



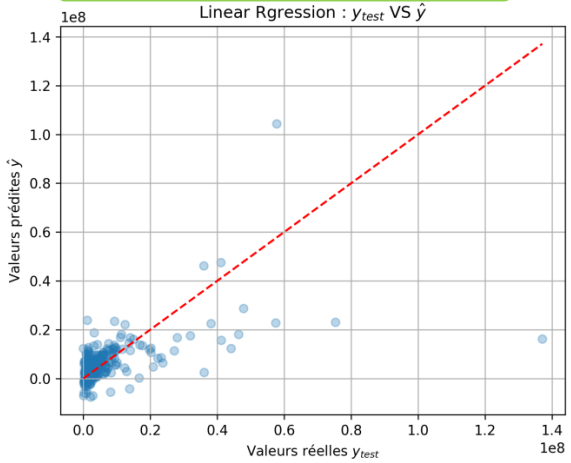
‘NumberofBuildings’ & ‘PropertyGFATotal’ : Variables très corrélées

Suppression de ‘NumberofBuildings’

Modélisation pour la prédiction

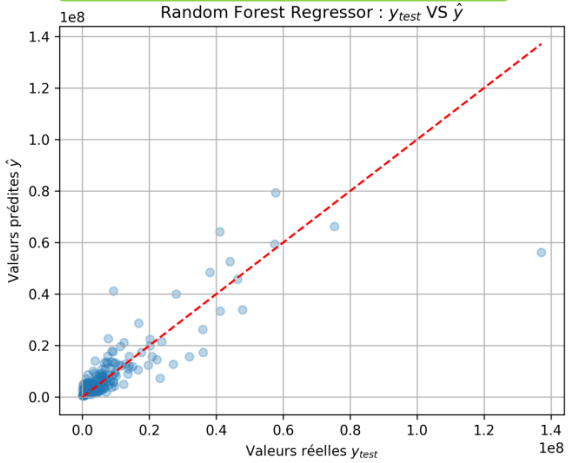
Comparaison de différents modèles supervisés (1/2) : Prédiction de la consommation d'énergie

Linear Reg.



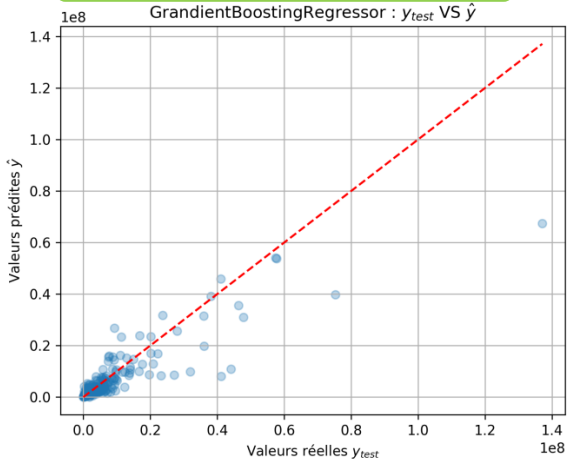
R2_train: 0.328
R2_test: 0.284
RMSE: 40295825.087
MAE: 6754478.391

Random Forest Reg.



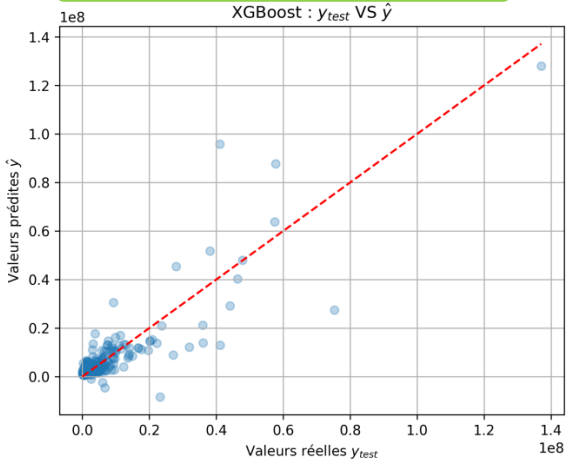
R2_train: 0.910
R2_test: 0.723
RMSE: 6533893.019
MAE: 2748427.701

Gradient Boosting Reg.



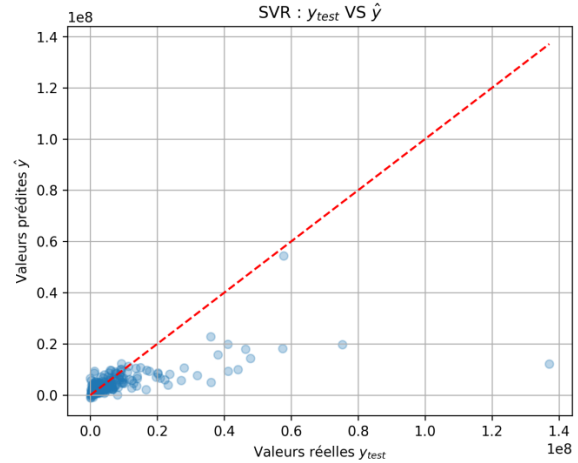
R2_train: 0.836,
R2_test: 0.735
RMSE: 6392666.194
MAE: 2469284.300

XGBoost



R2_train: 0.836
R2_test: 0.735
RMSE: 6392666.194
MAE: 2469284.300

SVR



R2_train: 0.226
R2_test: 0.317
RMSE: 10268340.327
MAE: 3646024.658